Решение кейса Drift-aware прогнозирование продаж

Команда 6-7

EDA

- PSI оценка
- Adversarial validation

PSI (target_2)

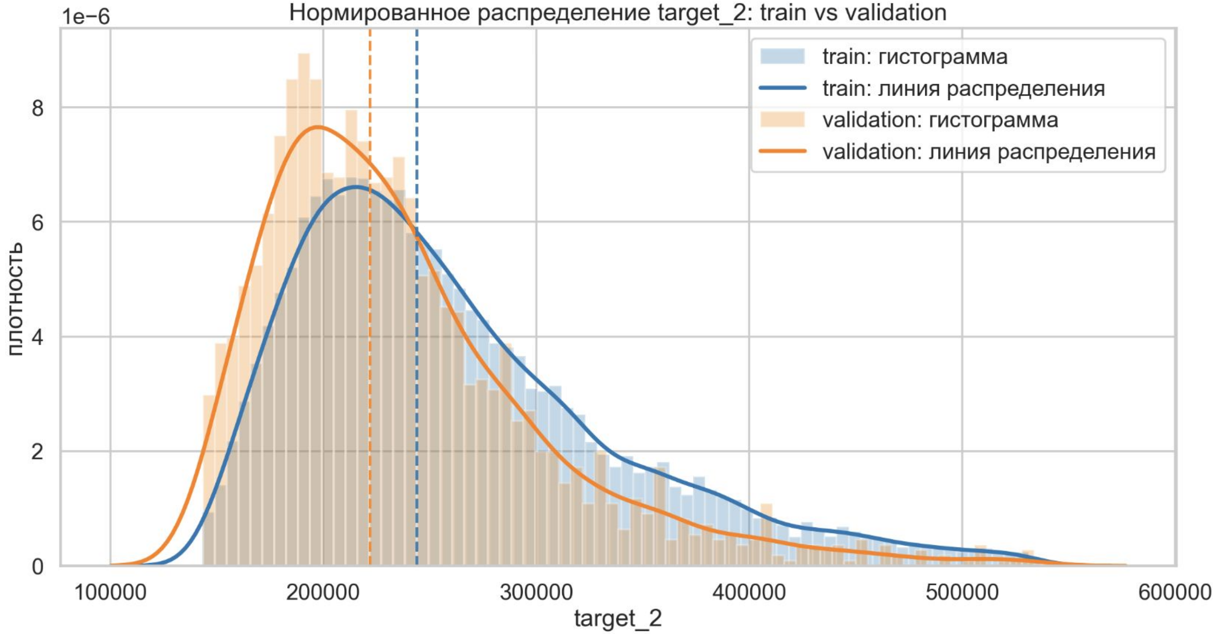

	PSI_val_vs_train
target_2	0.1542

PSI
(признаки)

	PSI_val_vs_train	PSI_holdout_vs_train	PSI_val_vs_holdout
month_count	11.5132	11.5132	11.5346
TRADING_PATCH_SCORE	0.2986	0.7050	0.0968
PARKING	0.1570	0.0566	0.0301
HuffRelativeFamilies	0.1535	0.1740	0.0269
HUFF_RANK_COMPS_CANNIBALS	0.1080	0.0728	0.0105
TRADE_SQUARE	0.0687	0.0692	0.0748
TOTAL_RANK_COMPS_CANNIBALS	0.0677	0.1856	0.0509
RENT_HEX	0.0612	0.0926	0.0213
DENSITY_FAMILY_TYPE	0.0473	0.1164	0.0153
KINDERGARTENS	0.0396	0.0415	0.0000
HuffFamilies	0.0342	0.0215	0.0322
DIST_TO_ADM_CENTER	0.0329	0.0204	0.0310
ROUTES_CNT	0.0060	0.0049	0.0047
CITY_TYPE	0.0020	0.0236	0.0118
REGION	0.0008	0.0016	0.0001

ROC-AUC Adversarial Validation

ROC-AUC = 1.0000

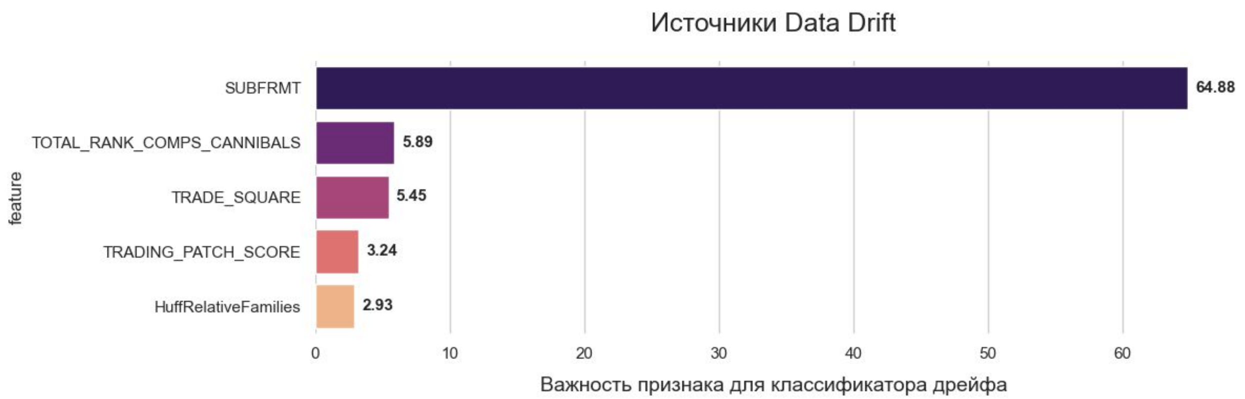

ROC-AUC = 0.9309

Feature Engineering

- Families_per_competitor = HuffFamilies / (Total_Rank + 1)
- Attraction_per_square = Patch_Score / (Trade_Square + 1e-6)
- Families_x_24h = HuffFamilies * Entire_Day
- Traffic_x_24h = Routes_Cnt * Entire_Day
- Families_x_attraction = HuffFamilies * Patch_Score

Модель

CatBoost with Quantile loss function

Features weights

Seed ensemble

Оптимизация весов признаков

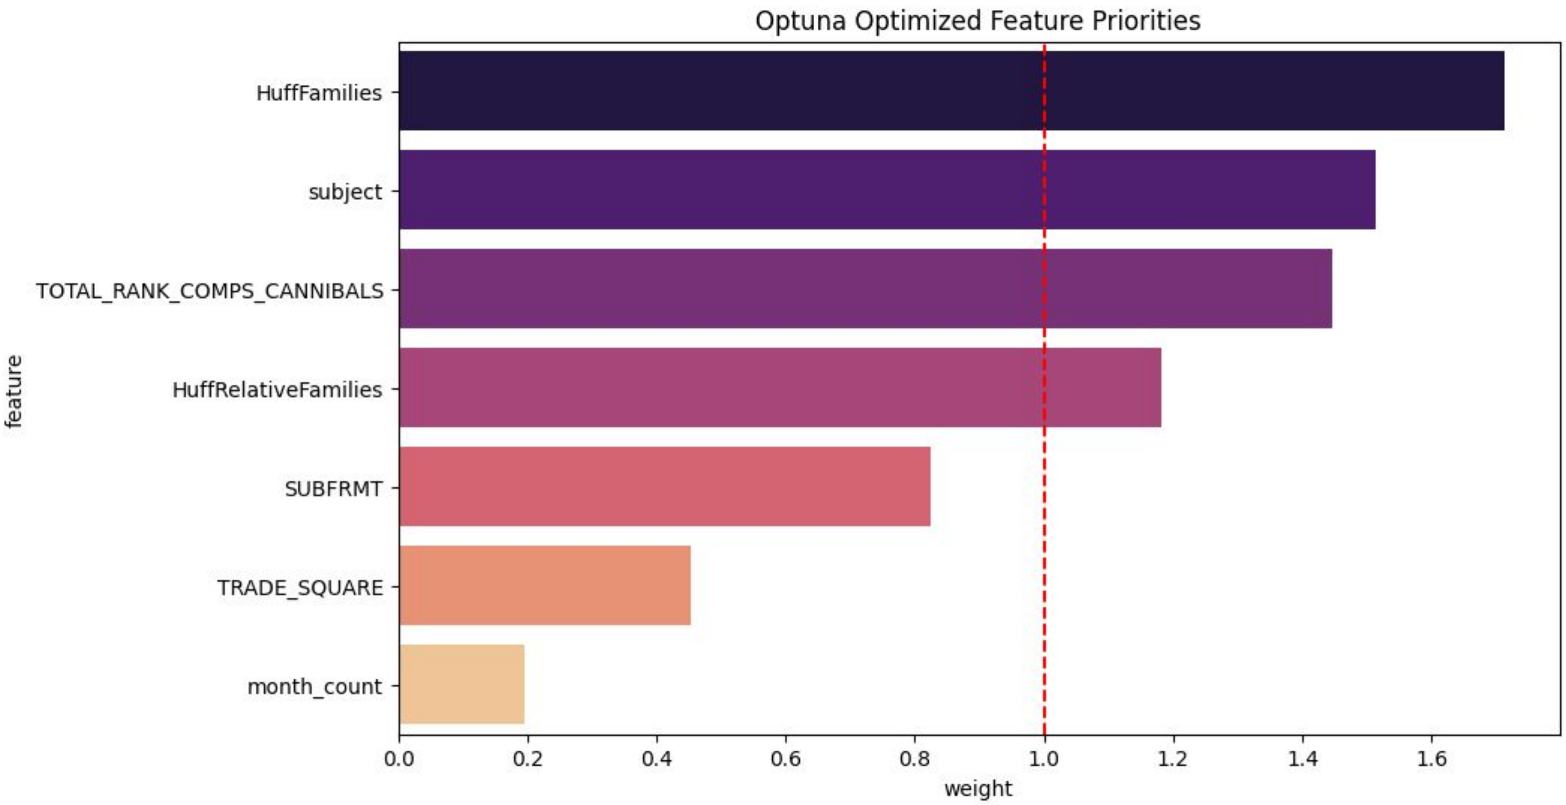

Ансамблирование с разным seed

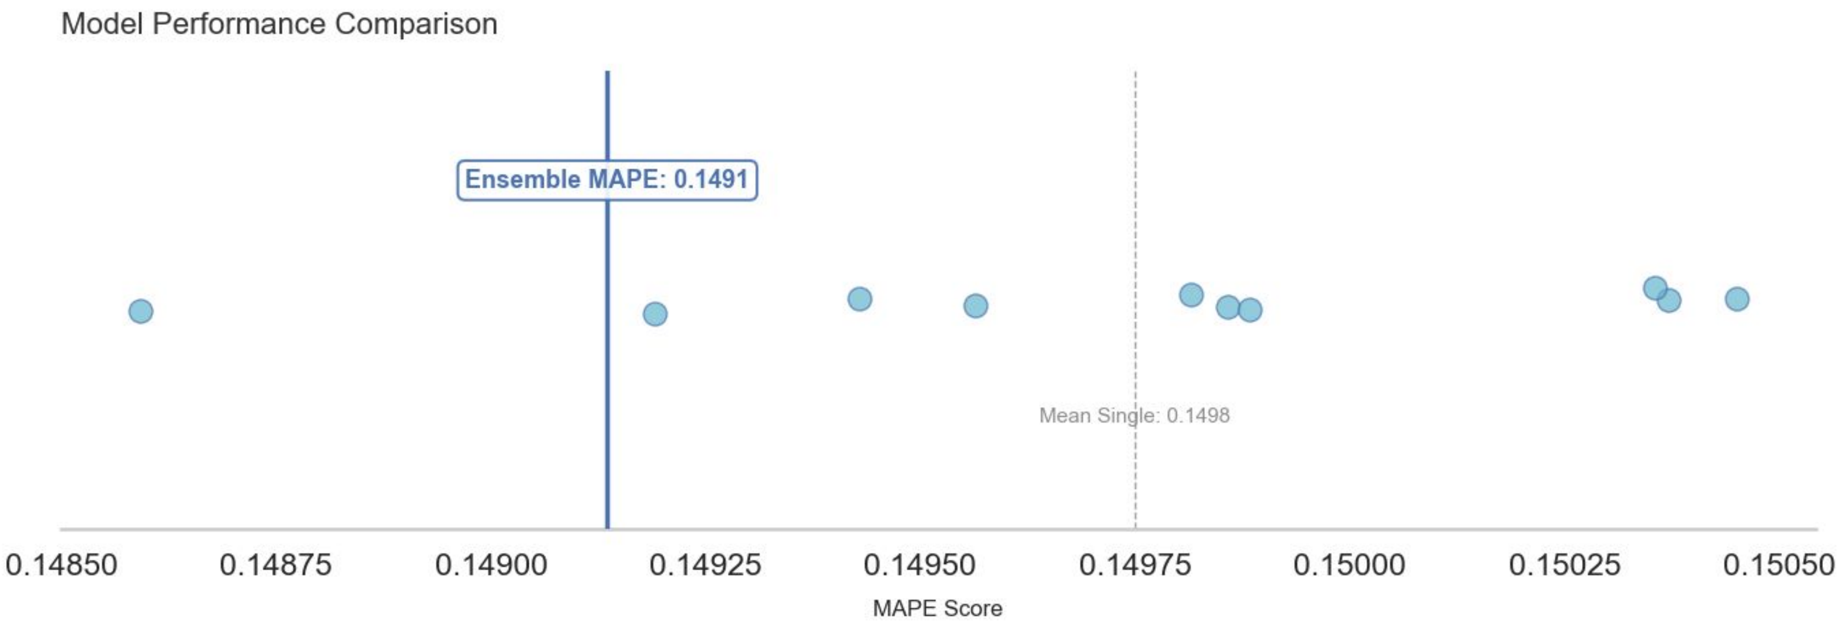

Интерпретация

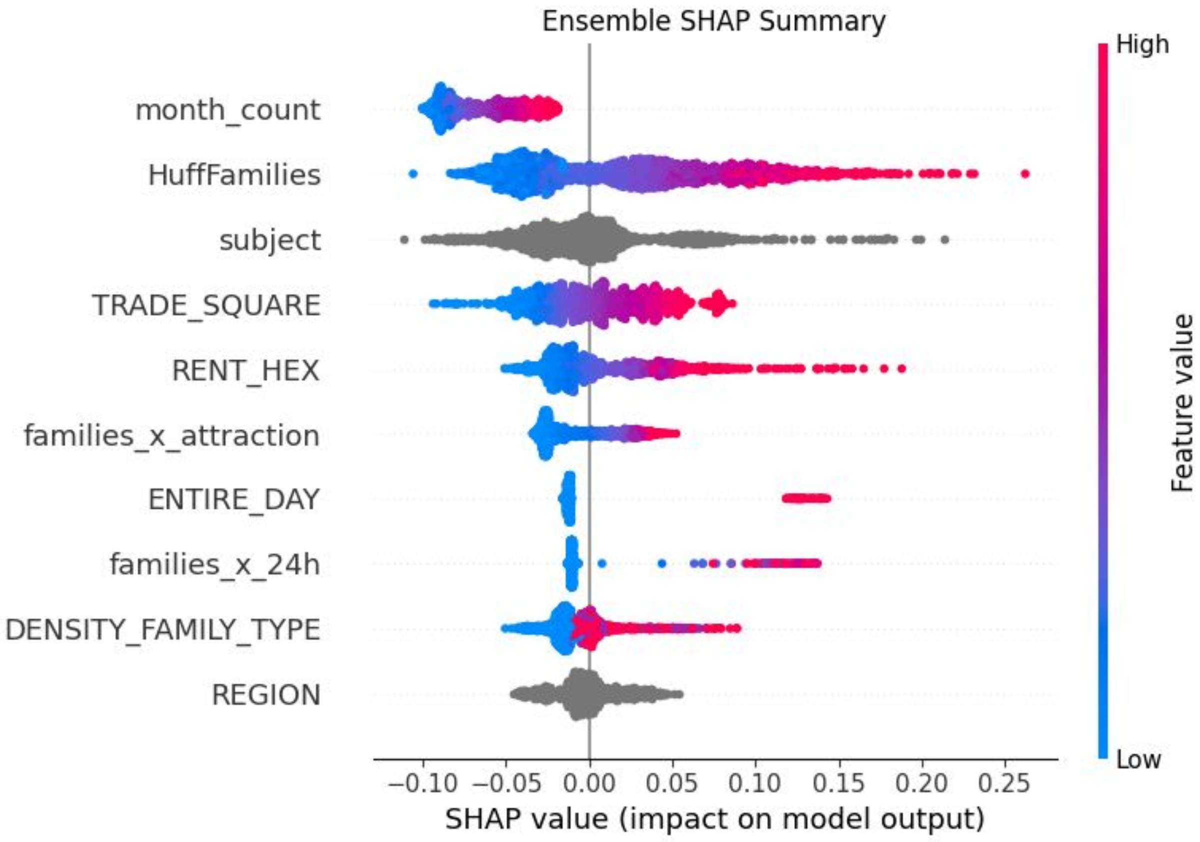

Альтернативные подходы

1. Кластеризация (PCA, HDBSCAN)
2. Линейные модели
3. Удаление признаков, вызывающих дрифт
4. Использование других функций потерь
5. Агрегатные признаки
6. Блендинг

Спасибо за внимание

Приложения

Корреляции

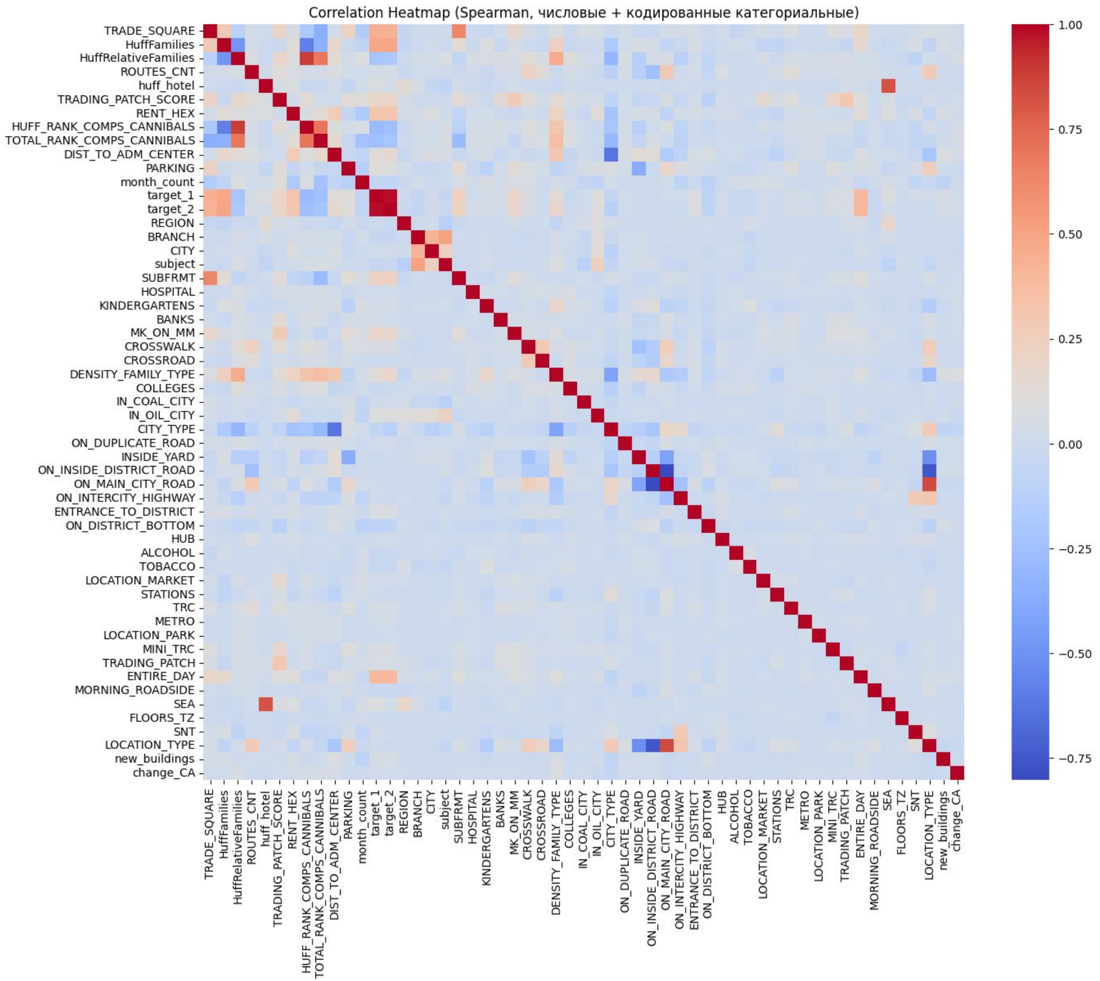
Correlation Heatmap (Spearman, числовые + кодированные категориальные)
TRADE_SQUARE
HuffFamilies
HuffRelativeFamilies
ROUTES_CNT
huff_hotel
TRADING_PATCH_SCORE
RENT_HEX
HUFF_RANK_COMPS_CANNIBALS
TOTAL_RANK_COMPS_CANNIBALS
DIST_TO_ADM_CENTER
PARKING
month_count
target_1
target_2
REGION
BRANCH
CITY
subject
SUBFRMT
HOSPITAL
KINDERGARTENS
BANKS
MK_ON_MM
CROSSWALK
CROSSROAD
DENSITY_FAMILY_TYPE
COLLEGES
IN_COAL_CITY
IN_OIL_CITY
CITY_TYPE
ON_DUPLICATE_ROAD
INSIDE_YARD
ON_INSIDE_DISTRICT_ROAD
ON_MAIN_CITY_ROAD
ON_INTERCITY_HIGHWAY
ENTRANCE_TO_DISTRICT
ON_DISTRICT_BOTTOM
HUB
ALCOHOL
TOBACCO
LOCATION_MARKET
STATIONS
TRC
METRO
LOCATION_PARK
MINI_TRC
TRADING_PATCH
ENTIRE_DAY
MORNING_ROADSIDE
SEA
FLOORS_TZ
SNT
LOCATION_TYPE
new_buildings
change_CA
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75

Разрез данных сделан по возрасту магазина
Тест
таргет скрыт
Валидация
Трейн
400000
350000
300000
250000
200000
target_2
50
100
150
200
250
300
Месяц работы магазина
Валидация: медиана target_2
Трейн: медиана target_2

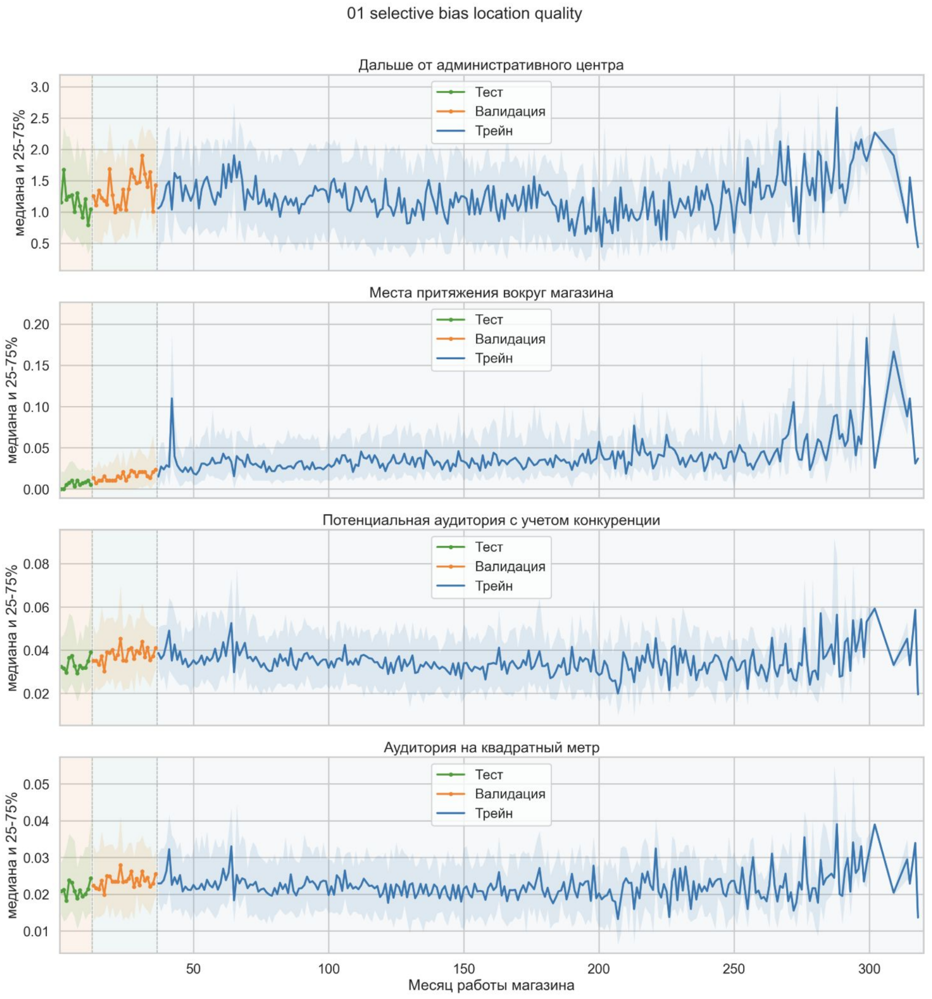

01 selective bias location quality
Дальше от административного центра
Места притяжения вокруг магазина
Потенциальная аудитория с учетом конкуренции
Аудитория на квадратный метр
Тест
Валидация
Трейн
медиана и 25-75%
Месяц работы магазина

02 competition and cannibalization

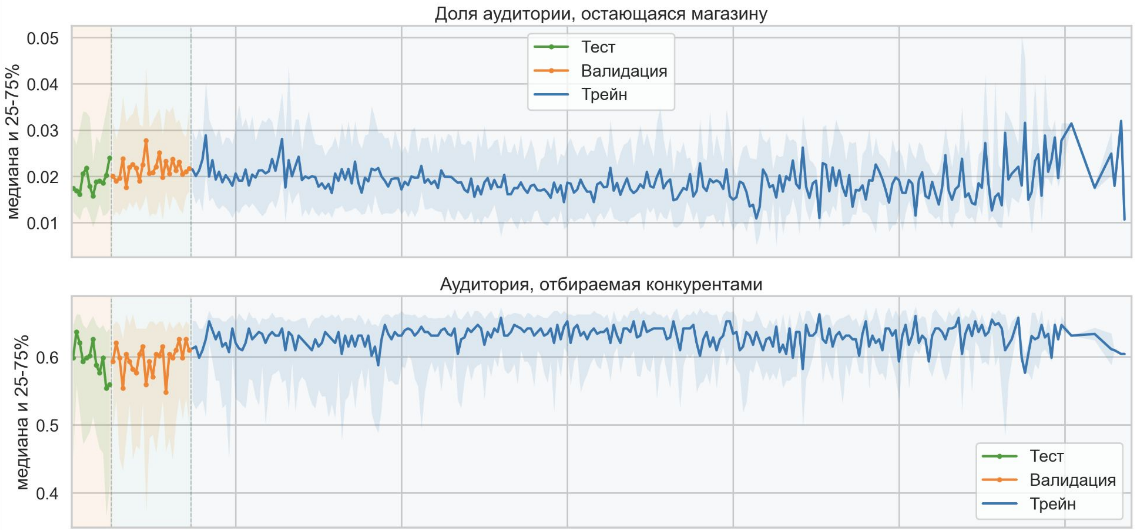

05 rent and monetization pressure

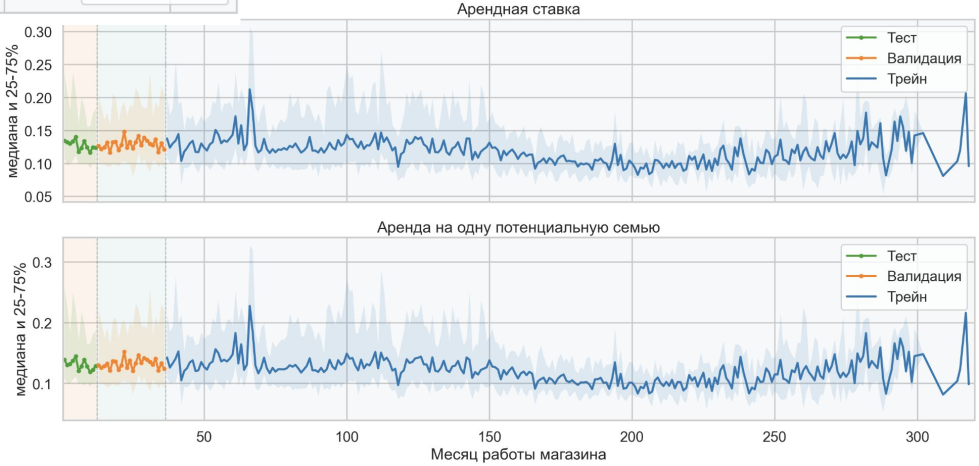

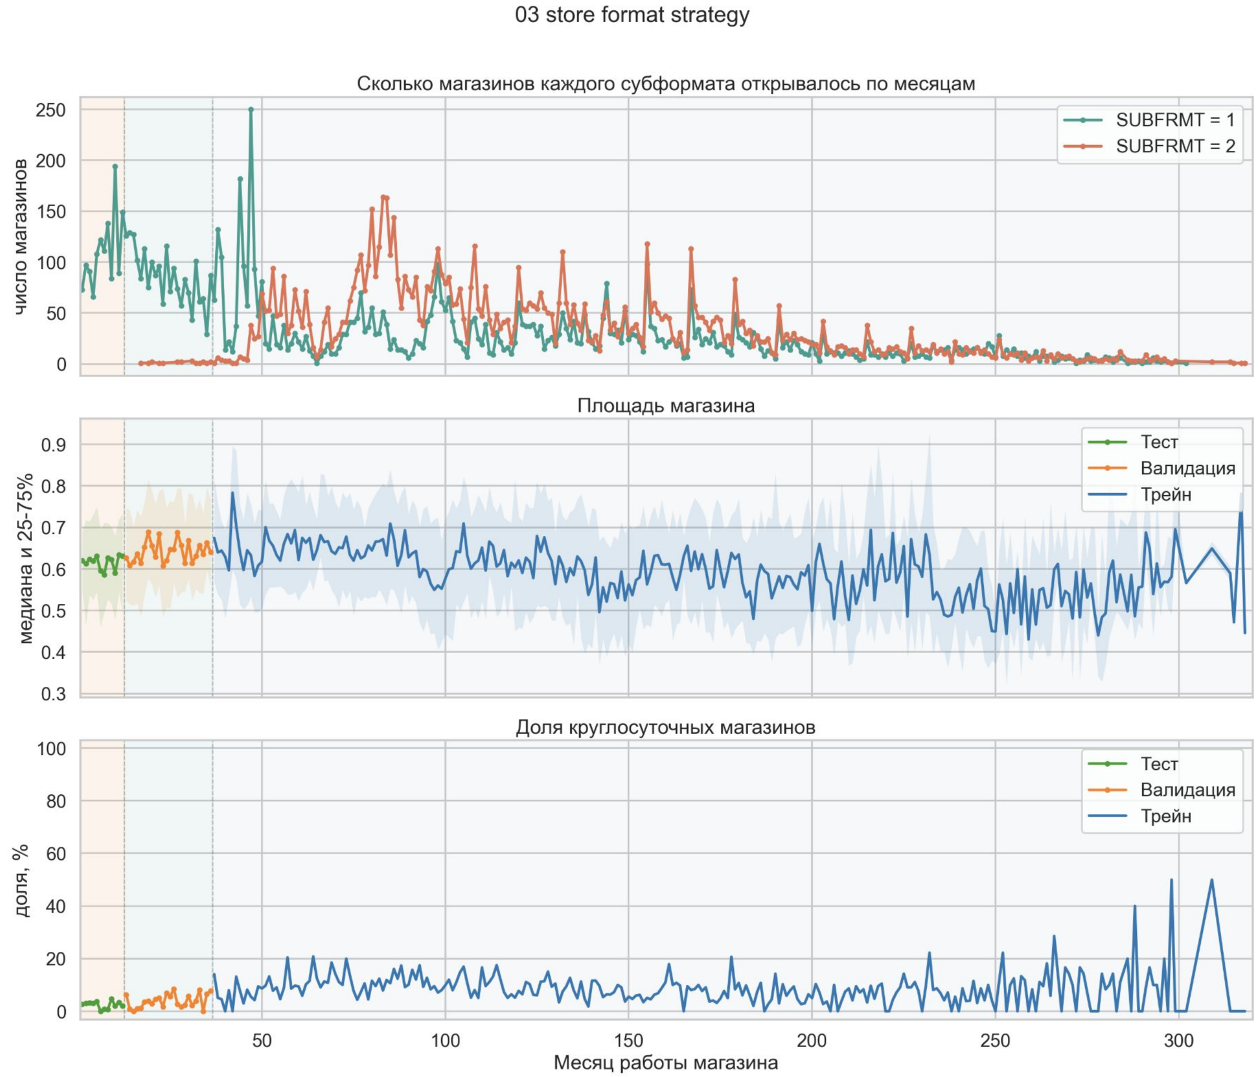
03 store format strategy
Сколько магазинов каждого субформата открывалось по месяцам
число магазинов
SUBFRMT = 1
SUBFRMT = 2
Площадь магазина
медиана и 25-75%
Тест
Валидация
Трейн
Доля круглосуточных магазинов
доля, %
Тест
Валидация
Трейн
Месяц работы магазина

04 accessibility and residential context

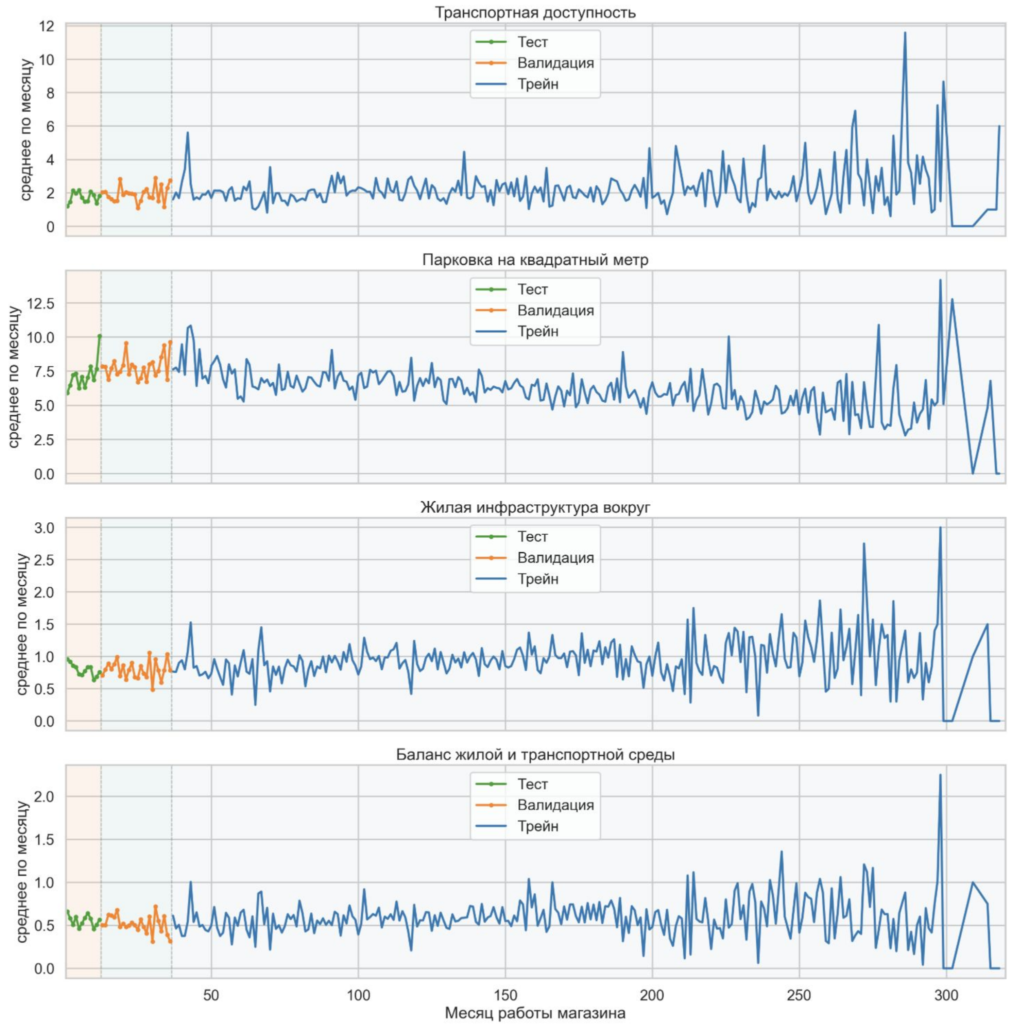

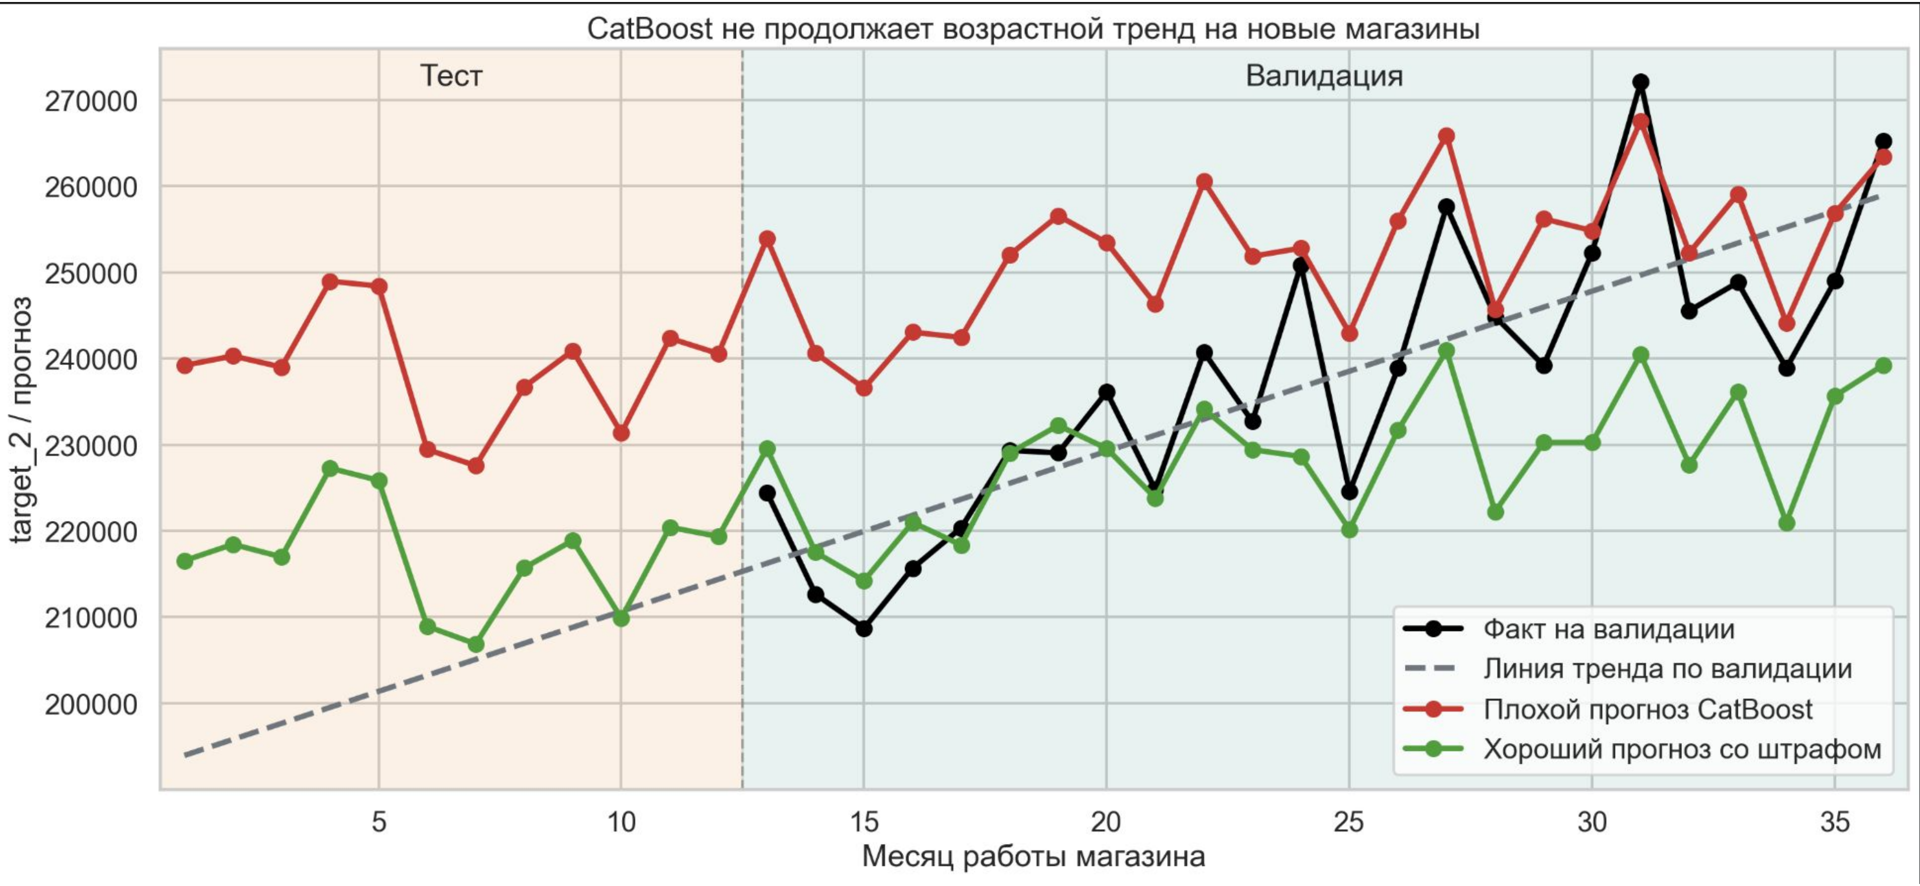
CatBoost не продолжает возрастной тренд на новые магазины
Тест
Валидация
270000
260000
250000
240000
230000
220000
210000
200000
target_2 / прогноз
5
10
15
20
25
30
35
Месяц работы магазина
Факт на валидации
Линия тренда по валидации
Плохой прогноз CatBoost
Хороший прогноз со штрафом